

Третье задание по БМСО

Ярослав Аверьянов

Октябрь 2015

1 Первая задача

$$\|P - Q\|_{TV} = 2 \cdot \sup_{B \in \mathbf{B}} |P(B) - Q(B)| - \text{общая дисперсия } P \text{ и } Q.$$

Для непрерывных распределений P и Q с плотностями p и q обозначим

$$\|P - Q\|_d = \int |p - q| d\mu$$

Докажем эквивалентность $\|\cdot\|_{TV}$ и $\|\cdot\|_d$ для непрерывных распределений.

Пусть $A = [x | p(x) - q(x) \leq 0] \in \mathbf{B}$ - замкнутое и измеримое множество.

Пусть $B \in \mathbf{B}$:

$$P(B) - Q(B) = \int_B (p(x) - q(x)) dx = \int_A (p(x) - q(x)) dx + \int_{B \setminus A} (p(x) - q(x)) dx - \int_{A \setminus B} (p(x) - q(x)) dx$$

$$\text{Где } \int_{B \setminus A} (p(x) - q(x)) dx \leq 0, \int_{A \setminus B} (p(x) - q(x)) dx \geq 0 \rightarrow P(B) - Q(B) \leq \int_A (p(x) - q(x)) dx = P(A) - Q(A)$$

$$\bar{A} = [x | p(x) - q(x) \geq 0]:$$

$$Q(B) - P(B) \leq Q(\bar{A}) - P(\bar{A}) = P(A) - Q(A).$$

$$\begin{aligned} \text{Поэтому } |P(B) - Q(B)| &\leq P(A) - Q(A). \rightarrow \|P - Q\|_{TV} = 2 \cdot \sup_{B \in \mathbf{B}} |P(B) - Q(B)| \\ &= 2 \cdot (P(A) - Q(A)) = P(A) - Q(A) - (1 - P(A)) + (1 - Q(A)) = \\ &= \int_A (p - q) d\mu + \int_{\bar{A}} (p - q) d\mu = \|p - q\|_d. \end{aligned}$$

2 Вторая задача

Пусть $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$. Используя то, что $d_{TV}(X, Y) = \frac{1}{2} \int_{-\infty}^{+\infty} |f(x) - g(x)| dx$, где f и g - плотности для X и Y . Далее предположим, что $\sigma_1 > \sigma_2$.

Введем следующие обозначения:

$$c = \frac{\sigma_1}{\sigma_2}, \quad \Delta = \frac{\mu_1 - \mu_2}{\sigma_2}$$

$$A = \frac{\sqrt{(c^2-1)2\log(c)+\Delta^2}-c\Delta}{c^2-1}, \quad B = -\frac{\sqrt{(c^2-1)2\log(c)+\Delta^2}+c\Delta}{c^2-1}$$

Используя эти обозначения:

$$\int_{-\infty}^{+\infty} |f(x) - g(x)| dx = \int_{-\infty}^{+\infty} |\phi(z) - c\phi(\Delta + cz)| dz$$

И $\phi(z) \leq c\phi(\Delta + cz) < - > A \leq z \leq B$. Следовательно

$$\int_{-\infty}^{+\infty} |f(x) - g(x)| dx = \int_A^B [c\phi(\Delta + cz) - \phi(z)] dz + \int_{-\infty}^A [\phi(z) - c\phi(\Delta + cz)] dz + \int_B^{+\infty} [\phi(z) - c\phi(\Delta + cz)] dz = 2[(\Phi(\Delta + cB) - \Phi(B)) - (\Phi(\Delta + cA) - \Phi(A))].$$

Где

$$\Delta + cB = \frac{c\sqrt{(c^2-1)2\log(c)+\Delta^2}-\Delta}{c^2-1}$$

$$\Delta + cA = -\frac{c\sqrt{(c^2-1)2\log(c)+\Delta^2}+\Delta}{c^2-1}$$

Если $\sigma_1 = \sigma_2$, формула сокращается до $\Phi(\frac{|\Delta|}{2}) - \Phi(-\frac{|\Delta|}{2})$

Следовательно, $d_{TV}(X, Y) = (\Phi(\Delta + cB) - \Phi(B)) - (\Phi(\Delta + cA) - \Phi(A))$

3 Третья задача

Показать, что если:

У1) множество параметров $\theta \in \Theta \subset \mathbf{R}$ - ограниченное открытое множество.

У2) $\exists \sigma > 0 : \forall \theta \in \Theta$ информация Фишера $I(\theta)$:

$$I(\theta) > \sigma > 0,$$

то для экспоненциального семейства распределений выполнено "предположение (5)" теоремы Бернштейна-фон-Мизеса.

Плотность распределения: $p(x|\theta) = \exp(-c(\theta) + \theta t(x))$

$1 = \int \exp(-c(\theta) + \theta t(x)) dx, c(\theta) = \ln \int \exp(\theta t(x)) dx$ - нормировка

$$c'(\theta) = \frac{\int t(x) \exp(\theta t(x)) dx}{\int \exp(\theta t(x)) dx} = \int \exp(-c(\theta) + \theta t(x)) t(x) dx = \mathbf{E}_\theta t(x)$$

Посчитаем информацию Фишера и логарифм правдоподобия:

$$\begin{aligned} I(\theta) &= -\mathbf{E}[l''(x|\theta)] = c''(\theta) > \sigma > 0 \\ L_n(\theta) &= \ln L(x_1, \dots, x_n|\theta) = -nc(\theta) + \theta \sum_{i=1}^n t(x_i) \\ \frac{1}{n}(L_n(\theta) - L_n(\theta_0)) &= c(\theta) - c(\theta_0) + \frac{1}{n}(\theta - \theta_0) \sum_{i=1}^n t(x_i). \end{aligned}$$

Так как

$$c(\theta) - c(\theta_0) \geq (\theta - \theta_0) \mathbf{E}_\theta t(x) + \frac{\sigma}{2}(\theta - \theta_0)^2$$

Получаем:

$$\frac{1}{n}(L_n(\theta) - L_n(\theta_0)) \leq (\theta - \theta_0)(-\mathbf{E}_\theta t(x) + \frac{1}{n} \sum_{i=1}^n t(x_i)) - \frac{\sigma}{2}(\theta - \theta_0)^2$$

Т.к. $\frac{1}{n} \sum_{i=1}^n t(x_i) \xrightarrow{P} \mathbf{E} t(x)$, $|\theta - \theta_0| < \gamma \rightarrow \forall \delta > 0 \exists \epsilon > 0 :$

$$\begin{aligned} P_{\theta_0}(\sup_{|\theta - \theta_0| < \delta} \frac{1}{n}(L_n(\theta) - L_n(\theta_0)) \leq -\epsilon) &\geq P_{\theta_0}(\gamma | -\mathbf{E} t(x) + \frac{1}{n} \sum_{i=1}^n t(x_i)| - \frac{\sigma}{2} \delta^2 < \\ -\epsilon) &= P_{\theta_0}(|-\mathbf{E} t(x) + \frac{1}{n} \sum_{i=1}^n t(x_i)| < \frac{1}{\gamma}(\frac{\sigma}{2} \delta^2 - \epsilon)) \rightarrow 1, \text{ где } \epsilon < \frac{\sigma}{2} \delta^2. \end{aligned}$$

4 Четвертая задача

Получить оценку максимального правдоподобия $\hat{\theta}_n$ и байесовскую оценку $\theta_n^* = \int \theta p(\theta|x_1, \dots, x_n) d\theta$ для среденего μ нормального распределения $N(\mu, \sigma^2)$ и априорного распределения $\theta \sim N(\mu_\Pi, \sigma_\Pi^2)$.

Посчитаем правдоподобие:

$$L(x_1, \dots, x_n|\theta) = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} \exp(-\frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2})$$

Оценка максимального правдоподобия:

$$\begin{aligned} \hat{\mu}_n &= \underset{\mu}{\operatorname{argmax}} L(x_1, \dots, x_n|\mu) = \underset{\mu}{\operatorname{argmax}} \exp(-\frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2}) = \\ &= \underset{\mu}{\operatorname{argmax}} \sum_{i=1}^n (x_i - \mu)^2 \rightarrow \hat{\mu}_n = \frac{1}{n} \sum_{i=1}^n x_i. \end{aligned}$$

Байесовская оценка $\mu_n^* = \int \mu \cdot p(\mu|x_1, \dots, x_n) d\mu$

Априорное распределение $\mu \sim N(\mu_\Pi, \sigma_\Pi^2)$

Апостериорное распределение:

$$\begin{aligned} p(\mu|x_1, \dots, x_n) &\propto L(x_1, \dots, x_n|\mu) \cdot p(\mu) \propto \exp\left(-\frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2} - \frac{(\mu^2 - 2\mu\mu_\Pi + \mu_\Pi^2)}{2\sigma_\Pi^2}\right) \propto \\ &\exp\left(-\frac{\mu^2}{2}\left(\frac{1}{\sigma^2} + \frac{n}{\sigma^2}\right) + \mu\left(\frac{\mu}{\sigma^2} + \frac{\sum_i x_i}{2\sigma^2}\right)\right) = \exp\left(-\frac{(\mu^2 - 2\mu\mu_n^* + \mu_n^{*2})}{2\sigma_n^{*2}}\right) = \\ &\exp\left(-\frac{(\mu - \mu_n^*)^2}{2\sigma_n^{*2}}\right) \end{aligned}$$

Байесовская оценка μ :

$$\mu_n^* = \frac{\frac{\mu_\Pi}{\sigma_\Pi^2} + \frac{\sum_i x_i}{\sigma^2}}{\frac{1}{\sigma_\Pi^2} + \frac{n}{\sigma^2}}$$

5 Пятая задача

Сравнить сходимость к нормальному распределению величин $\sqrt{n}(\theta_0 - \theta_n^*)$

и $\sqrt{n}(\theta_0 - \hat{\theta}_n)$.

Рассмотрим оценку максимального правдоподобия:

$$\hat{\theta}_n = \frac{1}{n} \sum_{i=1}^n x_i, \hat{\theta}_n \sim N(\theta_0, \frac{\sigma^2}{n}), \sqrt{n}(\theta_0 - \hat{\theta}_n) \sim N(0, \sigma^2)$$




Рис. 1: Стандартное нормальное распределение $N(0,1)$

Перейдем к байесовской оценке:

$$\text{Пусть } \theta \sim N(\theta_\Pi, \sigma_\Pi^2) \rightarrow \theta_n^* = \frac{\frac{\theta_\Pi}{\sigma_\Pi^2} + \frac{\sum_i x_i}{\sigma^2}}{\frac{1}{\sigma_\Pi^2} + \frac{n}{\sigma^2}}, \theta_n^* \sim N\left(\frac{\frac{\theta_\Pi}{\sigma_\Pi^2} + \frac{n\theta_0}{\sigma^2}}{\frac{1}{\sigma_\Pi^2} + \frac{n}{\sigma^2}}, \frac{n\sigma^2}{(\frac{\sigma_\Pi^2}{\sigma^2} + n)^2}\right)$$

$$(\theta_0 - \hat{\theta}_n^*) \sim N\left(\frac{\frac{1}{\sigma_{\Pi}^2}(\theta_{\Pi} - \theta_0)}{\frac{1}{\sigma_{\Pi}^2} + \frac{n}{\sigma^2}}, \frac{\frac{n\sigma^2}{(\frac{\sigma_{\Pi}^2}{\sigma^2} + n)^2}}{1 + \frac{n\sigma_{\Pi}^2}{\sigma^2}}\right) \sim N\left(\frac{(\theta_{\Pi} - \theta_0)}{1 + \frac{n\sigma_{\Pi}^2}{\sigma^2}}, \frac{\frac{n\sigma^2}{(\frac{\sigma_{\Pi}^2}{\sigma^2} + n)^2}}{1 + \frac{n\sigma_{\Pi}^2}{\sigma^2}}\right).$$

Т.к. $\theta_0 \sim N(\theta_{\Pi}, \sigma_{\Pi}^2) \rightarrow$

$$(\theta_0 - \hat{\theta}_n^*) \sim N\left(0, \frac{\frac{n\sigma^2}{(\frac{\sigma_{\Pi}^2}{\sigma^2} + n)^2}}{1 + \frac{n\sigma_{\Pi}^2}{\sigma^2}}\right)$$

Следовательно,

$$\sqrt{n}(\theta_0 - \hat{\theta}_n^*) \sim N\left(0, \frac{\frac{n^2\sigma^2}{(\frac{\sigma_{\Pi}^2}{\sigma^2} + n)^2} + \frac{\frac{n\sigma_{\Pi}^2}{\sigma^2}}{(1 + \frac{n\sigma_{\Pi}^2}{\sigma^2})^2}\right) \sim N\left(0, \frac{\frac{n^2\sigma^2 + \frac{n\sigma_{\Pi}^4}{\sigma^2}}{(\frac{\sigma_{\Pi}^2}{\sigma^2} + n)^2}}{1 + \frac{n\sigma_{\Pi}^2}{\sigma^2}}\right) \sim$$

$$N\left(0, \frac{\frac{\sigma^2}{\frac{\sigma_{\Pi}^2}{n\sigma^2} + 1}}{1 + \frac{n\sigma_{\Pi}^2}{\sigma^2}}\right).$$

Следовательно, для байесовской оценки мы получаем нормально распределенную случайную величину, с мат.ожиданием, равным нулю и дисперсией

$$\frac{\frac{\sigma^2}{\frac{\sigma_{\Pi}^2}{n\sigma^2} + 1}}{1 + \frac{n\sigma_{\Pi}^2}{\sigma^2}};$$

Возьмем $\sigma = 1, \sigma_{\Pi} = \frac{1}{2}$:




Рис. 2: $N(0, \frac{1}{1 + \frac{4}{n}})$ при $n = 1, 10, 100$